FinComercial, S.A.

Analítica inteligente para anticipar el riesgo

REPORTE COMPARATIVO · ACTIVIDAD 5

FinPredict

Evaluación de modelos supervisados, deuda técnica y estrategia MLOps para riesgo hipotecario

Propósito del documento

Comparar regresión logística y Random Forest mediante resultados verificables; interpretar métricas y visualizaciones; identificar deuda técnica; y sustentar una decisión de continuidad bajo criterios de operación, ética y MLOps.

CAMPO	INFORMACIÓN
Organización	FinComercial, S.A.
Responsable	Lizbeth Bruno Lorenzana · AI Lead
Asignatura	Gestión de Proyectos de Inteligencia Artificial
Fecha	18/10/2026
Versión	1.0 · Cierre analítico Actividad 5

Repositorio técnico: github.com/lizlorenzana931109-art/FinPredict-Actividad5

1. Resumen ejecutivo

Síntesis de resultados, compensaciones operativas y decisión propuesta.

390,661	2	40,141	0.8641
registros preparados	modelos comparados	observaciones finales	PR-AUC final RF

DIMENSIÓN	RESULTADO / LECTURA EJECUTIVA
Problema	Anticipar incumplimiento hipotecario de 90 días para priorizar intervenciones preventivas.
Diseño	Datos sintéticos; validación temporal expansiva en tres particiones y evaluación final separada.
Hallazgo	Random Forest mejora PR-AUC en 0.0064 puntos y recall en 26.24 puntos porcentuales frente a logística en validación.
Contrapartida	Regresión logística supera a Random Forest en F1; el entrenamiento de la búsqueda de Random Forest es más costoso.
Impacto operativo	En evaluación final: 2,127 verdaderos positivos, 155 falsos negativos y 1,829 falsas alertas.
Recomendación	Continuar a una validación piloto controlada con supervisión humana; no habilitar decisiones automáticas sobre clientes.

Decisión ejecutiva | GO condicionado para validación; NO-GO para producción

El desempeño sintético sustenta continuar investigando, no desplegar. Priorizar control de alertas falsas, evaluación con datos reales, umbral operativo sujeto a capacidad, gobierno de datos y seguimiento de desempeño y equidad.

2. Caso de uso y protocolo experimental

Diseño de comparación y controles para reducir optimismo por uso de información futura.

OBJETIVO DEL MODELO

Estimar el riesgo de presentar mora de al menos 90 días durante el horizonte posterior al corte. La solución propuesta es una priorización preventiva para equipos de Riesgo y Operaciones; no modifica contratos ni emite decisiones crediticias autónomas.

COMPONENTE	EVIDENCIA DOCUMENTADA
Base preparada	390,661 observaciones por contrato-periodo; 44,913 contratos distintos.
Desarrollo	350,520 observaciones; 21,368 eventos positivos.
Evaluación reservada	40,141 observaciones; 2,282 eventos positivos; corte 30/09/2025, horizonte 2025-T4.
Variables	14 predictores numéricos; exclusión de identificadores y datos personales sintéticos del entrenamiento.
Optimización	GridSearchCV; métrica de selección: Average Precision (PR-AUC).
Validación	Tres ventanas temporales expansivas; sin ajustar parámetros en el conjunto final.

SECUENCIA METODOLÓGICA

01 Preparar · Normalización, imputación y controles de consistencia

02 Validar · Ventanas temporales de entrenamiento y validación

03 Optimizar · GridSearchCV para logística y Random Forest

04 Seleccionar · PR-AUC promedio en validación temporal

05 Evaluar · Un holdout final independiente para Random Forest

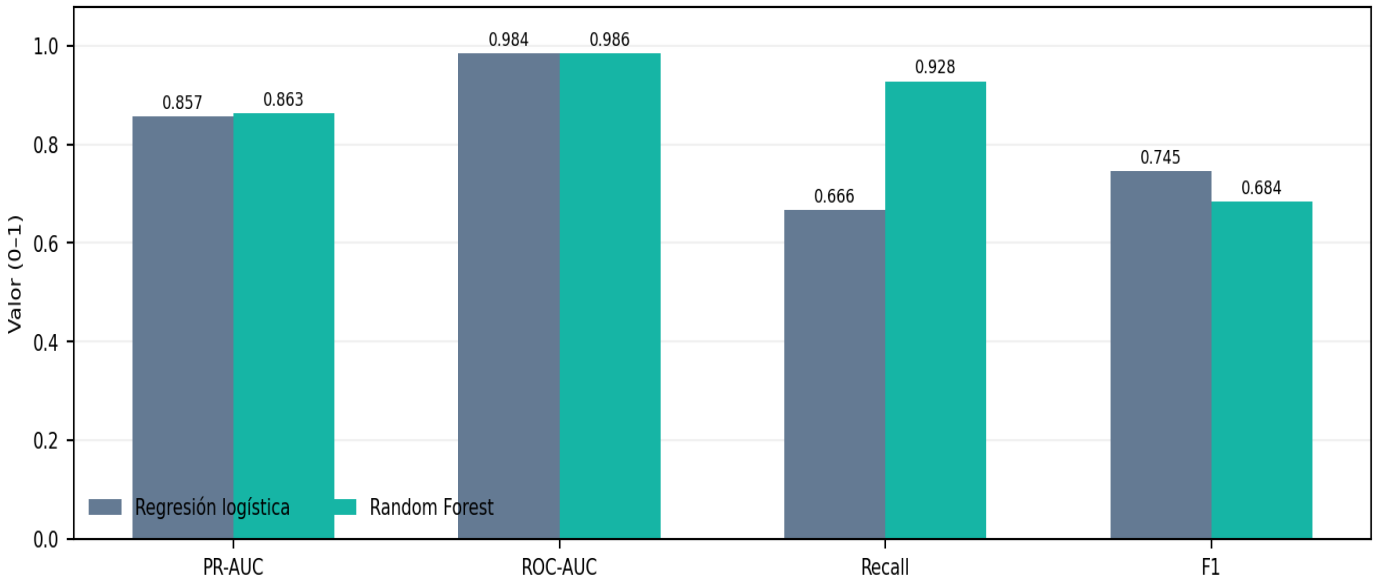
Control temporal

El tratamiento de medianas históricas de ingreso faltante se recalculó por fold durante el modelado para evitar que la información de validación alimentara el ajuste. Aun así, su implementación y auditoría deben consolidarse en un pipeline único para producción.

3. Comparación de modelos

Resultados promedio de validación temporal; cifras redondeadas a cuatro decimales.

MÉTRICA	LOGÍSTICA	RANDOM FOREST	LECTURA
PR-AUC	0.8567	0.8631	RF +0.0064
ROC-AUC	0.9844	0.9855	RF +0.0011
Recall	0.6661	0.9284	RF +0.2624
F1-score	0.7452	0.6843	Logística +0.0609
Tiempo de búsqueda	18.83 s	1,069.77 s	RF ≈56.8 veces



LECTURA TÉCNICA DE LA VISUALIZACIÓN

La figura evidencia que Random Forest mejora sobre todo la sensibilidad (recall) y conserva una ventaja pequeña en PR-AUC; regresión logística conserva mejor F1 a umbral 0.50. La diferencia de PR-AUC (0.0064) es descriptiva, no una prueba de significancia estadística.

Criterio de selección

Se priorizó PR-AUC por la prevalencia relativamente baja de incumplimiento. La selección de Random Forest es defendible para detección preventiva, pero el umbral y la tasa de alertas deben ajustarse con Riesgo y Operaciones antes de usarlo.

4. Análisis estadístico básico y alcance

Comparaciones descriptivas sustentadas en métricas registradas; no se inventan pruebas de hipótesis.

INDICADOR	CÁLCULO	INTERPRETACIÓN
Prevalencia final	2,282 / 40,141 = 5.68 %	Evento minoritario; accuracy aislada no es suficiente.
Cobertura del evento	2,127 / 2,282 = 93.21 %	Detecta la gran mayoría de casos positivos del holdout.
Valor predictivo positivo	2,127 / 3,956 = 53.77 %	Aproximadamente 46.23 % de alertas serían falsos positivos.
Especificidad	36,030 / 37,859 = 95.17 %	Controla la mayoría de negativos, pero genera 1,829 alertas falsas.
F1 final	0.6819	Equilibrio precision-recall en el umbral usado.
Generalización temporal	PR-AUC CV 0.8631 → final 0.8641	Cambio +0.0010; estabilidad descriptiva en simulación.

ALCANCE Y LIMITACIONES DE LA INFERENCIA

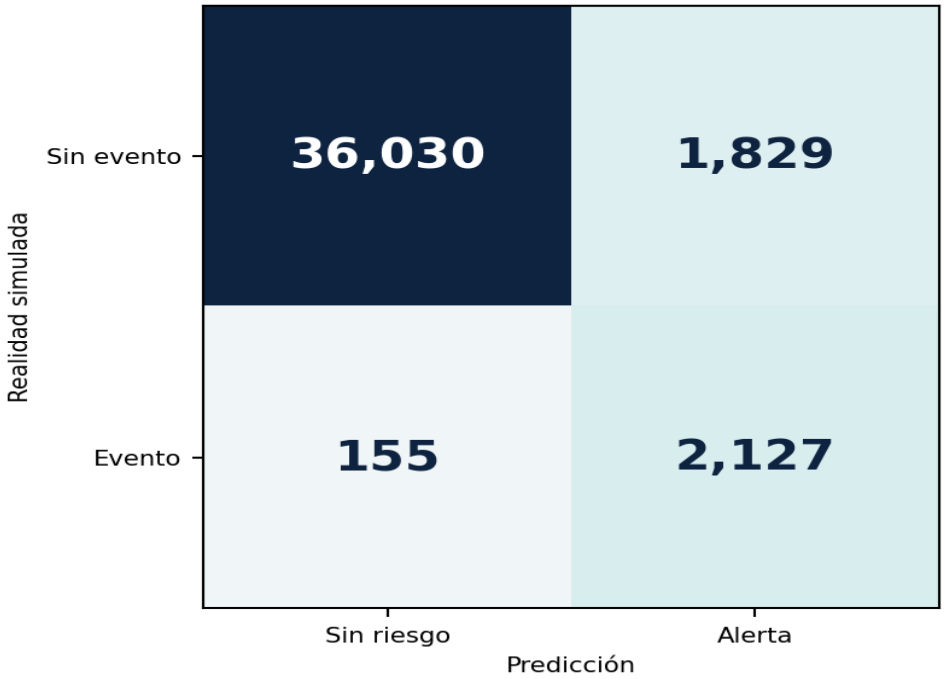
- No equivale a significancia estadística: no se calcularon intervalos de confianza, pruebas de hipótesis ni bootstrap pareado. No afirmar superioridad estadística concluyente.
- Dependencia longitudinal: un contrato puede contribuir con múltiples cortes; los registros no deben suponerse independientes en inferencia convencional.
- Datos sintéticos: la aparente estabilidad temporal y métricas elevadas pueden reflejar patrones propios del generador y no necesariamente el comportamiento de una cartera real.
- Comparación final: solo Random Forest se evaluó en el holdout final una vez seleccionado por CV; la comparación justa entre algoritmos se basa en CV, no en extrapolar un resultado final inexistente para logística.

Recomendación estadística para la siguiente fase

Estimar incertidumbre con remuestreo por contrato (bootstrap agrupado), registrar métricas por ventana y segmento, comparar curvas PR y calibración sobre datos independientes, y acordar criterios de aceptación antes de nuevos experimentos.

5. Matriz de confusión y lectura de negocio

Evaluación única sobre 40,141 observaciones reservadas, corte 30 de septiembre de 2025.



TIPO	N	SIGNIFICADO OPERATIVO
Verdaderos positivos	2,127	Clientes-periodo con evento detectado correctamente.
Falsos negativos	155	Eventos sin alerta; oportunidad preventiva omitida.
Falsos positivos	1,829	Contactos o revisiones innecesarias si se actúa sobre toda alerta.
Verdaderos negativos	36,030	Observaciones sin evento clasificadas correctamente.

Interpretación de la visualización

La matriz muestra un intercambio central: alta detección del evento a costa de un volumen apreciable de falsas alertas. Si se revisaran todas las 3,956 alertas positivas, cerca de 1 de cada 2 no correspondería a un incumplimiento observado en el horizonte simulado.

6. Deuda técnica y plan de remediación

Limitaciones identificadas y acciones priorizadas bajo un enfoque de ciclo de vida MLOps.

DEUDA / BRECHA	RIESGO	ACCIÓN PROPUESTA	PRIORIDAD
Entrenamiento distribuido en notebooks	Diferencias entre ejecuciones y dificultad de mantenimiento.	Empaquetar pipeline, pruebas unitarias y ejecución parametrizada.	Alta
Estado MLflow local (SQLite / rutas Colab)	Restauración frágil, trazabilidad dependiente de sesión.	Backend y artefactos persistentes administrados; acceso controlado.	Alta
Versionado manual y datos sintéticos	Reproducibilidad limitada y brecha con realidad.	Versionar datasets y esquemas, checksum, linaje y validación de calidad.	Alta
Umbral 0.50 no optimizado para operación	Exceso de alertas frente a capacidad de respuesta.	Calibración y selección de corte por costo/capacidad; pruebas shadow.	Alta
Sin monitoreo productivo	Cambios de distribución y degradación no detectados.	Dashboard de datos, calidad, drift, PR-AUC diferido y alertas.	Alta
Sin auditoría de equidad real	Impacto desproporcionado sobre grupos de clientes.	Auditoría por segmentos permitidos y revisión de decisiones.	Alta
Modelo como archivo .joblib	Falta promoción formal y rollback gobernado.	Model Registry, versionado, aprobaciones y procedimiento de reversión.	Media

Priorización ejecutiva

Primero asegurar calidad, linaje y validación con datos representativos; después establecer umbral y controles de uso; por último industrializar despliegue y monitorización. La sofisticación de la infraestructura no sustituye la validez del modelo.

7. Arquitectura MLOps y gobierno

Diseño propuesto para evolucionar la prueba de concepto; no implementado en producción.

FLUJO OPERATIVO RECOMENDADO

01 **Fuentes autorizadas**
S3 + calidad y esquema

↓

02 **Feature pipeline**
Versionado + tests

↓

03 **Entrenamiento**
CV temporal + MLflow

↓

04 **Aprobación**
Riesgo + Compliance

↓

05 **Scoring controlado**
Batch / shadow mode

↓

06 **Monitoreo**
Drift + desempeño + equidad

CONTROLES DE GESTIÓN

- Datos: esquemas, validación de rango, nulos, duplicados, calidad de etiquetas y fechas de disponibilidad.
- Modelo: registro de versión, métricas por ventana, aprobación de umbral, pruebas de regresión y rollback.
- Operación: medición del volumen de alertas, adopción, revisiones humanas, acciones y resultados.
- Seguridad: accesos mínimos, cifrado, auditoría y segregación de ambientes.

8. Riesgos éticos, controles y continuidad

Propuesta de gobernanza responsable para un posible piloto hipotecario.

RIESGO	CONSECUENCIA	MITIGACIÓN EXIGIBLE
Falso positivo	Contacto inoportuno o trato injustificado.	Revisión humana, explicación del motivo y política de no sanción.
Falso negativo	No detectar una dificultad emergente.	Revisión complementaria y monitoreo de recall por segmento.
Sesgo / discriminación	Prioridades desiguales entre poblaciones.	Evaluar equidad con variables permitidas, metodología auditada y plan correctivo.
Privacidad	Exposición de información económica sensible.	Minimización, acceso por rol, cifrado, retención y trazabilidad.
Explicabilidad	Escasa confianza y difícil impugnación.	Interpretación global/local, validación por Riesgo y ruta de revisión.
Datos sintéticos	Modelo sin validez externa comprobada.	Piloto con datos reales autorizados y holdout independiente.

CONDICIONES PARA AUTORIZAR UN PILOTO

- Calidad, cobertura, legitimidad de tratamiento y disponibilidad temporal de las variables, aprobadas por Datos y Cumplimiento.
- Evaluación prospectiva con datos representativos; métricas, calibración y diferencias por segmentos documentadas.
- Capacidad de revisión de las alertas y procedimiento de contacto preventivo definido por Operaciones.
- Controles de explicabilidad, seguridad, registro de decisiones humanas y mecanismo para suspender el modelo.

> **Principio de gobierno**
>
> El modelo sugiere prioridades, pero no determina rechazos de crédito, cambios contractuales ni decisiones adversas automatizadas. Toda intervención requiere políticas aprobadas y revisión humana.

9. Decisión final y hoja de ruta

Plan propuesto para convertir evidencia experimental en valor sin comprometer controles.

FASE	ENTREGABLE / CRITERIO DE SALIDA	RESPONSABLE PROPUESTO
0 · Validación de datos	Diccionario, linaje, esquemas, prueba de disponibilidad y partición temporal autorizada.	Data Engineering + Riesgo
1 · Validación de modelo	PR-AUC, recall, precision, calibración, segmentos e intervalos; línea base y costos definidos.	Data Science + Riesgo
2 · Prueba operativa	Shadow mode; volumen de alertas, tiempos de revisión, seguimiento de falsos positivos.	Operaciones + Producto
3 · Industrialización	CI/CD, registro de modelos, monitoreo, rollback y controles de accesos.	MLOps + Seguridad
4 · Decisión de escalamiento	Comité evalúa valor, equidad, estabilidad, capacidad y riesgos residuales.	Comité Riesgo/Negocio

CONCLUSIONES SUSTENTADAS

- 1. Random Forest lideró la métrica de optimización PR-AUC (0.8631 vs. 0.8567); su ventaja absoluta es pequeña y descriptiva.
- 2. Aumentó el recall de validación, pero redujo F1 y demandó mucho mayor tiempo de búsqueda; elegirlo exige valorar capacidad operativa.
- 3. En evaluación final logró PR-AUC 0.8641 y recall 93.21 %, pero originó 1,829 falsas alertas; el desempeño por sí solo no certifica utilidad económica.
- 4. La evidencia de MLflow incluye corridas, hiperparámetros, métricas, artefactos y respaldo; no existe despliegue ni registro formal en Model Registry.
- 5. Corresponde un GO condicionado a validación piloto y un NO-GO a producción automática hasta demostrar validez externa, control de riesgo y beneficio tangible.

Conclusión ejecutiva

El siguiente paso no es entrenar más modelos sin objetivo. Es convertir la comparación ya realizada en una prueba controlada, establecer condiciones de aceptación con el negocio y demostrar valor sin comprometer a los clientes.

10. Trazabilidad, uso de IA y referencias

Fuentes del proyecto, alcance de la asistencia generativa y cierre documental.

EVIDENCIAS VERIFICABLES

RECURSO	EVIDENCIA
fuentes/01_construccion_dataset.ipynb	Generación y diseño sintético.
fuentes/02_preparacion_datos.ipynb	Calidad, limpieza, imputación y datasets v1.
fuentes/03_modelado_experimentacion.ipynb	Validación temporal, GridSearchCV y evaluación final.
evidencias/mlflow/	Capturas auténticas de ejecuciones, métricas, parámetros y artefactos.
evidencias/mlflow/resultados/	CSV de configuraciones exploradas para ambos modelos.
datos/datos_limp/	Datasets preparados y manifiesto de versión.

DECLARACIÓN DE IA GENERATIVA

Se utilizó ChatGPT como apoyo en estructuración y depuración de código, razonamiento metodológico, documentación del repositorio, análisis de resultados y redacción del presente informe. Las métricas y artefactos experimentales proceden de ejecuciones realizadas en Google Colab y registradas en MLflow; la asistencia generativa no reemplaza la verificación técnica ni las decisiones de la autora.

REFERENCIAS Y MARCO DOCUMENTAL

- FinPredict. (2026). FinPredict - Actividad 5: repositorio técnico. GitHub. https://github.com/lizlorenzana931109-art/FinPredict-Actividad5
- MLflow. (s. f.). MLflow Tracking. https://mlflow.org/docs/latest/ml/tracking/
- scikit-learn developers. (s. f.). GridSearchCV. https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html
- scikit-learn developers. (s. f.). Average precision score. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.average_precision_score.html
- National Institute of Standards and Technology. (2023). Artificial Intelligence Risk Management Framework (AI RMF 1.0). https://doi.org/10.6028/NIST.AI.100-1

NOTA METODOLÓGICA FINAL

Los resultados y cálculos del informe se basan en las métricas y conteos reportados para esta actividad. Las acciones de gobierno, arquitectura y umbrales operativos son recomendaciones propuestas; no se presentan como controles ya implementados. El dataset es sintético y no permite afirmar impacto financiero efectivo ni desempeño con clientes reales.